



UNIVERSITÀ DEGLI STUDI DI SALERNO
Corso di Laurea Magistrale in Informatica

FONDAMENTI DS & ML

Nuclear Feature Selection for Breast Tumor Diagnosis

DOCENTI

Prof. Giuseppe Polese
Prof. Gaetano Cimmino
Prof. Giandomenico Solimando

STUDENTI

Michele Antonio Annunziata
Raffaele Coppola

Anno accademico 2025-2026

Indice

1	Introduzione al problema	3
1.1	Dominio applicativo	3
1.2	Tumore al seno	3
1.2.1	Neoplasie	3
1.2.2	Epidemiologia, proiezioni e tasso di sopravvivenza	3
1.3	Il dataset Wisconsin	4
1.3.1	FNA	4
1.3.2	Estrazione automatica delle caratteristiche nucleari	4
1.3.3	Riduzione della dimensionalità	4
1.4	Domanda di ricerca	5
1.4.1	Criterio di valutazione	5
2	Metodi e Materiali	6
2.1	EDA e pre-processing	7
2.1.1	Analisi della multicollinearità	7
2.1.2	Rilevamento delle anomalie	8
2.2	Architettura della pipeline	10
2.2.1	Nested cross-validation	10
2.2.2	Step della pipeline	11
2.2.3	Test di Welch	12
2.2.4	Selezione del modello migliore	13
2.2.5	Modelli di apprendimento	14
3	Risultati ottenuti	16
3.1	Confronto tra approcci di ricerca	16
3.2	Valutazione dei modelli	17
3.2.1	Matrici di confusione	17

3.2.2	Tempi di inferenza	19
3.3	Explainability	19
3.3.1	Spazio delle feature	20
3.3.2	Importanza delle feature	21
4	Conclusioni	23

Elenco delle figure

1	Correlazione tra variabili indipendenti.	8
2	Distribuzione degli anomaly score	10
3	Nested cross-validation	11
4	Confronto valori medi per gruppo	13
5	Confronto tra approcci di ricerca.	16
6	Matrici di confusione per ciascuna combinazione modello-approccio di ricerca. . .	18
7	Importanza delle feature tramite SHAP - SVC (grid)	22

Elenco delle tabelle

1	Descrizione delle 10 caratteristiche morfologiche di base misurate su ciascun nucleo cellulare	6
2	Descrizione dei 3 fattori di aggregazione calcolati per ogni caratteristica morfologica	7
3	Sintesi dei risultati dell'Isolation Forest	9
4	Confronto tra approcci di ricerca.	17
5	Risultati ottenuti con soglia di probabilità ottimizzata.	19
6	Tempo medio di inferenza sull'intero test set.	19
7	Frequenza caratteristiche sopravvissute alla pipeline.	20
8	Dimensionalità media dello spazio delle feature per modello.	21

1 Introduzione al problema

1.1 Dominio applicativo

L'applicazione del **Machine Learning** (ML) in ambito medico ha come obiettivo principale quello di supportare i processi decisionali del personale sanitario nell'analisi di una diagnosi. In questo settore, i sistemi **Computer-Aided Diagnosis** (CAD), nati inizialmente per l'elaborazione di immagini radiologiche, non svolgono una funzione sostitutiva nei riguardi del medico, bensì implementano il paradigma del **secondo lettore**: il clinico esegue una prima valutazione autonoma del quadro patologico; il sistema analizza i dati, evidenzia eventuali anomalie o fattori di rischio e fornisce al patologo un supporto quantitativo per confermare la diagnosi o prioritizzare i casi più critici.

Detenere metodi automatici per una diagnosi precoce e per l'individuazione del peggioramento dello stato delle cose potrebbe banalmente evitare numerose ospedalizzazioni, diminuire l'onere logistico e finanziario per il sistema sanitario ed aumentare al contempo la qualità di vita dei pazienti.

1.2 Tumore al seno

1.2.1 Neoplasie

Alterazioni del proprio patrimonio genetico possono determinare una proliferazione anomala di cellule. Tale crescita scoordinata e incontrollata è detta **neoplasia** ("*nuova formazione*") ed è alla base di una vasta classe di malattie, tra cui tumori benigni (non cancerosi) e maligni (cancro). La branca della medicina che si occupa di studiare l'eziologia, le diagnosi e le terapie dei tumori prodotti da processi di questo tipo è chiamata oncologia. Tendenzialmente, non si intende solamente effettuare diagnosi di neoplasie già presenti, ma anche individuare eventuali cellule precancerose in un contesto di prevenzione.

1.2.2 Epidemiologia, proiezioni e tasso di sopravvivenza

Tra le neoplasie più diffuse vi è la *neoplasia mammaria* (o tumore al seno) che, con circa 2.4 milioni di nuovi casi e 694.000 decessi, si colloca al secondo posto per incidenza e al quarto per mortalità su tutti i tipi di cancro; considerando le sole donne, è invece il tumore più comune sia per incidenza che per mortalità a livello mondiale [1]. A questo carico si affianca una marcata disparità legata allo sviluppo socioeconomico: nei paesi con un indice di sviluppo umano (HDI) molto alto, 1 donna su 12 riceve una diagnosi di cancro al seno nel corso della vita e 1 su 71 ne muore, mentre nei paesi a basso HDI il rapporto è di 1 su 27 per la diagnosi ma di 1 su 48 per la mortalità, a indicare un rapporto mortalità/incidenza nettamente peggiore [2]. Le proiezioni verso il 2050 confermano questa tendenza, mostrando come l'aumento di nuovi casi e decessi avrà un impatto sproporzionato proprio sui paesi a basso HDI [3].

Questo divario riflette in larga parte le differenze nell'accesso alla diagnosi precoce, la cui importanza è resa evidente dai dati di sopravvivenza per stadio: la sopravvivenza relativa a 5

anni supera il 99% per le diagnosi in stadio localizzato, scende all'87% per lo stadio regionale (coinvolgimento di tessuti limitrofi) e crolla al 32% per lo stadio distante (tumore diffuso in altri organi) [4]. Non a caso, nei paesi in cui sono svolti programmi di screening all'avanguardia, il tasso di mortalità per cancro al seno è diminuito negli ultimi decenni [4].

1.3 Il dataset Wisconsin

1.3.1 FNA

Quando, durante un esame clinico o un accertamento radiologico (ecografia o mammografia), si individua un nodulo sospetto, una delle procedure diagnostiche più comuni e poco invasive è l'agoaspirato (*Fine Needle Aspirate* - **FNA**). Questa consiste nell'introduzione di un ago sottile all'interno della massa sospetta, con successiva aspirazione per mezzo di una siringa la quale permette di prelevare un campione di cellule, il cui materiale viene steso su piccole lastre di vetro allo scopo di esser esaminato al microscopio da un citopatologo.

1.3.2 Estrazione automatica delle caratteristiche nucleari

Sulla base di immagini digitalizzate dei vetrini di FNA, nel 1993 fu sviluppato un sistema di elaborazione automatica che ha consentito di calcolare, per ciascun nucleo isolato, 10 grandezze morfologiche di base [5]. Per ciascuna di queste 10 caratteristiche, sull'insieme dei nuclei individuati nel campione si calcolano tre statistiche riassuntive:

- la **media** (**mean**);
- l'**errore standard** (**error**);
- la **media dei tre valori più estremi** (**worst**);

Da questo processo deriva il noto dataset **Breast Cancer Wisconsin (Diagnostic)**, composto da 569 unità campionarie che rappresentano gli esiti dell'esame dei pazienti descritti da 30 feature continue (10 misurazioni di base moltiplicate per i 3 fattori di aggregazione) e un target binario finale che ne definisce la diagnosi (benigno vs maligno).

1.3.3 Riduzione della dimensionalità

All'aumentare del numero di dimensioni (feature), il volume dello spazio dei dati cresce così rapidamente che i punti diventano sempre più distanti, richiedendo un numero di unità campionarie che cresce esponenzialmente per ottenere una generalizzazione statistica affidabile — un fenomeno noto in letteratura come **maledizione della dimensionalità** (*curse of dimensionality*). A parità di numero di unità campionarie, l'accuratezza media di un classificatore aumenti inizialmente con il numero di feature ma, superata una certa soglia ottimale, tenda a peggiorare.

Nel presente lavoro questo aspetto risulta particolarmente rilevante in quanto il rapporto unità/dimensioni è tutt'altro che favorevole, il che motiva ulteriormente, oltre alla questione della multicollinearità, l'adozione di un criterio rigoroso di riduzione dello spazio delle feature.

1.4 Domanda di ricerca

Nel lavoro originale [5], gli autori si concentrarono principalmente sul processo di estrazione automatica delle feature e sulla dimostrazione che l'applicazione di procedure di programmazione lineare applicato su un sottoinsieme ristretto di feature potesse separare le due classi. Gli autori non definirono tuttavia un metodo sistematico e automatizzato di **feature selection** per gestire le 30 variabili sottostanti.

Colmare questa lacuna rappresenta l'obiettivo di fondo del presente lavoro. Nello specifico, ci si propone di sostituire l'esplorazione manuale con un criterio rigoroso integrato in una pipeline predefinita, verificandone la capacità di ridurre lo spazio delle feature senza comprometterne le capacità diagnostiche.

RQ. Nella diagnosi del cancro al seno, un criterio automatico e riproducibile di Feature Selection basato su test statistico univariato (t-test di Welch) - applicato su diversi modelli - permette di ottenere prestazioni diagnostiche robuste?

1.4.1 Criterio di valutazione

La scelta della metrica di valutazione non è arbitraria, ma discende direttamente dalla natura del dominio applicativo. In un problema di classificazione binaria come questo, la matrice di confusione distingue quattro esiti possibili:

- **veri positivi** (TP): tumore maligno, correttamente classificato come maligno;
- **veri negativi** (TN): tumore benigno, correttamente classificato come benigno;
- **falsi positivi** (FP): tumore benigno, erroneamente classificato come maligno;
- **falsi negativi** (FN): tumore maligno, erroneamente classificato come benigno.

In un sistema di supporto diagnostico occorre stabilire una priorità esplicita coerente con l'asimmetria del costo clinico dei due tipi di errore. In tali scenari l'obiettivo primario è quello di **minimizzare i falsi negativi**, il che equivale a massimizzare la **recall** (o *sensitivity*). Falsi positivi comportano approfondimenti diagnostici superflui che difficilmente compromettono l'esito clinico in modo diretto. D'altro canto, se un tumore realmente maligno viene classificato erroneamente come benigno, il paziente non riceve tempestivamente il trattamento necessario e, il ritardo diagnostico permette alla neoplasia di progredire verso stadi più avanzati con un impatto misurabile sulla sopravvivenza (sottosottosezione 1.2.2).

2 Metodi e Materiali

Il dataset impiegato in questo lavoro è il *Breast Cancer Wisconsin (Diagnostic)*, recuperato programmaticamente tramite l'API di `scikit-learn` ⁽¹⁾. Come già discusso sopra, esso è composto da 569 osservazioni e 31 colonne, di cui 30 feature numeriche continue e una variabile target binaria, che identifica la natura della massa analizzata. Un'osservazione rilevante riguarda la variabile target: nella codifica nativa di `scikit-learn`, il valore 1 corrisponde a un esito benigno e il valore 0 a un esito maligno; una convenzione contro-intuitiva, in cui la classe "positiva" numericamente non coincide con l'evento clinicamente più rilevante. Onde evitare ambiguità nella successive fasi, è stata applicata una trasformazione per invertire tale codifica, ottenendo la convenzione standard 0 = benigno, 1 = maligno.

Inizialmente il dataset riporta 212 casi maligni e 357 casi benigni (rapporto approssimativo 63/37), presentano dunque un moderato sbilanciamento tra le due classi.

Come anticipato in sottosezione 1.1, per ciascuna delle 10 caratteristiche di base il dataset non riporta una singola misurazione per campione, ma tre statistiche riassuntive. La Tabella 1 riassume il significato delle caratteristiche morfologiche di base, mentre la Tabella 2 mostra le descrizioni dei fattori di aggregazione.

Tabella 1: Descrizione delle 10 caratteristiche morfologiche di base misurate su ciascun nucleo cellulare

Caratteristica	Descrizione
radius	Media delle distanze dal centro del nucleo ai punti sul suo perimetro.
texture	Deviazione standard dei valori di scala di grigio (grayscale) all'interno del nucleo, indice della rugosità/tessitura della cromatina.
perimeter	Lunghezza del contorno del nucleo.
area	Area della superficie del nucleo.
smoothness	Variazione locale della lunghezza dei raggi, ossia quanto il contorno del nucleo si discosta localmente da una forma liscia/regolare.
compactness	Calcolata come $\frac{\text{perimetro}^2}{\text{area}} - 1,0$; misura quanto il nucleo si discosta da una forma circolare perfetta (valori più alti indicano forme più irregolari/allungate).
concavity	Severità delle porzioni concave del contorno del nucleo.
concave points	Numero di porzioni concave presenti nel contorno del nucleo.
symmetry	Grado di simmetria della forma del nucleo.
fractal dimension	Stima della dimensione frattale del contorno, calcolata secondo l'approssimazione "coastline" (Mandelbrot) meno 1; quantifica l'irregolarità/complessità del bordo su scale diverse.

¹https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html

Tabella 2: Descrizione dei 3 fattori di aggregazione calcolati per ogni caratteristica morfologica

Fattore di aggregazione	Descrizione
mean	Media aritmetica del valore sull'insieme dei nuclei.
worst	Media dei tre valori più estremi (i tre nuclei con valore più elevato) tra quelli osservati.
error	Errore standard della media (misura della dispersione dei valori tra i diversi nuclei della stessa immagine).

2.1 EDA e pre-processing

Tutte le operazioni descritte in questa sottosezione sono state condotte sull'intero set di dati a scopo meramente esplorativo ed investigativo, in una fase appunto di **Exploratory Data Analysis** (EDA). Qualsiasi eventuale decisione basata su queste analisi, verrà ricalcolata esclusivamente sul fold di training di ciascuna iterazione della nested cross-validation che definisce l'intera pipeline, scongiurando fenomeni di data leakage.

2.1.1 Analisi della multicollinearità

Si parla di **multicollinearità** nel momento in cui i valori assunti da una variabile indipendente dipendono particolarmente dai valori assunti da una (o più) variabile indipendente distinta, rendendo la sua variabilità quasi interamente predicibile a partire da altre variabili. In casi di alta correlazione tra due variabili indipendenti, vi è una ridondanza legata al fatto che queste veicolano una parte dell'informazione speculare.


Il motivo principale per cui si desidera individuare le multicollinearità è il fatto che esse comportano l'aumento della dimensionalità effettiva dello spazio delle feature su cui agisce il modello, senza però aggiungere reale potere discriminante.

Lo strumento che di consueto si utilizza per visualizzare le relazioni lineari tra tutte le variabili indipendenti è la matrice di correlazione. In questo caso però, invece di calcolarne un'unica di lettura complessa (matrice 30×30), sono state prodotte tre matrici distinte, una per ciascuna coppia di fattori di aggregazione (**mean** vs **worst**, **mean** vs **error**, **worst** vs **error**). In ciascuna di queste matrici, sulle righe sono riportate le feature del primo gruppo (fattore di aggregazione) della coppia, sulle colonne le feature del secondo gruppo, e ciascuna cella ospita il corrispondente coefficiente di correlazione di Pearson.

Osservando la matrice "**mean** vs **worst**" presente in Figura 1a si può notare come le celle sulla diagonale principale, ossia quelle che confrontano la stessa caratteristica morfologica nei due gruppi (es. **mean_radius** vs **worst_radius**), presentano sistematicamente valori assai alti. Tale situazione è in realtà una conseguenza matematica della definizione dei fattori di aggregazione stessi: i valori sono calcolati a partire dalla medesima distribuzione di misurazioni; ci si aspetta quindi, per costruzione, che le due variabili abbiano una tendenza concorde.

È stata anche calcolata la correlazione tra ciascuna variabile indipendente e la variabile dipendente **target**. In Figura 1b si osserva un grafico a barre che ordina dall'alto verso il basso, in senso non crescente, le feature in base al valore effettivo di coefficiente di correlazione con il **target**.

Figura 1: Correlazione tra variabili indipendenti.



Sebbene gli approcci basati su matrici di correlazione possano fornire informazioni preziose, essi hanno un limite intrinseco: catturano esclusivamente relazioni *bivariate*, cioè tra due variabili alla volta. Una feature può presentare correlazioni a due a due modeste con ciascun'altra variabile, pur essendo la sua varianza quasi perfettamente ricostruibile mediante una combinazione lineare di più variabili. Per superare questo limite e impiegare una tecnica in grado di rilevare forme di ridondanza multivariata, è stato utilizzato il **Variance Inflation Factor** (VIF). Operativamente, detto p il numero di variabili indipendenti, per ogni feature X_i si calcola una regressione lineare considerando X_i come variabile dipendente fittizia e le restanti $p - 1$ feature come regressori. Dal modello si estrae il coefficiente di determinazione $0 \leq R_i^2 \leq 1$ che ne valuta la bontà di adattamento e si definisce il VIF come

$$\text{VIF}(X_i) = \frac{1}{1 - R_i^2}$$

Se il regressore lineare non riesce affatto a spiegare la variabilità di X_i attraverso le altre $p - 1$ ($R_i^2 = 0$), il VIF assume il valore minimo pari a 1 (nessuna inflazione della varianza). Al contrario, se X_i è quasi perfettamente spiegabile dalle altre variabili ($R_i^2 \rightarrow 1$), allora $\text{VIF} \rightarrow \infty$. In letteratura si adottano comunemente soglie indicative (ad esempio $\text{VIF} > 5$ o > 10) oltre le quali la multicollinearità è considerata problematica.

2.1.2 Rilevamento delle anomalie

L'*anomaly detection* è il processo di identificazione di osservazioni, eventi o dati che si discostano in modo significativo dal comportamento generale dei dati. Poche anomalie possono distorcere in modo significativo le rappresentazioni dei dati, introducendo rumore che compromette la capacità dei modelli predittivi di poter covare dei pattern.

A differenza della maggioranza dei metodi di anomaly detection che si concentrano sul concetto di normalità, l'**Isolation Forest** si basa su un principio per cui le osservazioni anomale sono

poche e diverse, ergo risulta naturale isolarle dalle osservazioni "normali" che tendono a collocarsi in regioni dense [6].

L'algoritmo costruisce un ensemble di alberi di isolamento (*isolation trees*), ciascuno dei quali viene costruito ricorsivamente: ad ogni nodo, si seleziona casualmente una feature ed un suo valore casuale tra quelli osservati; viene effettuato un taglio di separazione dei dati in base a tale soglia e si ripete ricorsivamente fino a che ogni osservazione risulta isolata in una foglia separata (o viene raggiunta una profondità massima prefissata).

L'intuizione chiave è che un'osservazione anomala, essendo per definizione "discostante" dalla massa dei dati, richiede orientativamente pochi split per essere isolata rispetto ad un'osservazione classica che è immersa in una regione sovraffollata. Formalmente, per ciascuna osservazione x si definisce la *lunghezza del cammino* $h(x)$ come il numero di split (archi) attraversati dalla radice dell'albero fino alla foglia che isola x . A valle di questo, per ciascuna osservazione viene assegnato un **anomaly score** ottenuto tramite la seguente formula

$$s(x, n) = 2^{-\frac{E[h(x)]}{c(n)}}$$

dove n è il numero di osservazioni, $E[h(x)]$ è la lunghezza del cammino medio sull'intero ensemble di alberi e $c(n)$ è un fattore di normalizzazione. I valori assunti da tale score sono nell'intervallo $(0, 1]$: maggior è il valore di questo punteggio, più forte sarà il segnale di anomalia.

Allo scopo di effettuare una classificazione finale di ciascuna osservazione come *inlier* o *outlier* bisogna definire una soglia, che rappresenta la proporzione attesa a priori di osservazioni anomale del dataset. Ponendo tale soglia 98° percentile della distribuzione degli score, tutte le osservazioni con punteggio superiore a tale soglia vengono etichettate come outlier (-1), le restanti come inlier ($+1$).


Tabella 3: Sintesi dei risultati dell'Isolation Forest

Parametro	Valore
Osservazioni totali	569
Inlier (prediction = +1)	557
Outlier (prediction = -1)	12
Soglia (98° percentile)	0.5767

Applicando questa procedura alle 569 osservazioni del dataset, si ottengono i risultati riassunti in Tabella 3.

La Figura 2 riporta l'istogramma della distribuzione dei punteggi di anomalia su tutte le 569 osservazioni. La linea verticale tratteggiata di colore rosso è disposta in corrispondenza della soglia di decisione (0.5767) e delinea la piccola coda di osservazioni identificate come outlier. L'asimmetria verso valori moderati conferma la condizione predominante di normalità del dataset.

Figura 2: Distribuzione degli anomaly score



2.2 Architettura della pipeline

2.2.1 Nested cross-validation

Il limite significativo di una valutazione adottando un semplice *train/test split* risiede nella forte influenza del fattore caso sui risultati ottenuti.


Un miglioramento consiste nell'implementare una strategia di validazione incrociata. Tuttavia, se la stessa procedura viene utilizzata sia per ottimizzare gli iperparametri che per stimare le prestazioni finali, si ha un bias ottimistico: gli iperparametri vengono selezionati proprio perché massimizzano le prestazioni su quegli specifici fold di validazione, per cui la prestazione media riportata su quegli stessi fold trascura la vera capacità di generalizzazione del modello su dati mai visti.

Per rendere indipendente il processo di configurazione (*tuning*) degli iperparametri e la stima delle prestazioni, si implementa una strategia di validazione incrociata (stratificata) annidata (**nested cross-validation**) -Figura 3):

- un **outer loop** (composto da k_{outer} fold) dedicato alla robustezza delle prestazioni di generalizzazione;
- un **inner loop** (composto da k_{inner} fold) dedicato alla selezione degli iperparametri migliori, eseguito separatamente all'interno dell'outer loop.

La procedura prevede una suddivisione stratificata iniziale in k_{outer} fold. Per ciascuna delle k_{outer} iterazioni, un fold viene accantonato come *outer test set* e i restanti $k_{\text{outer}} - 1$ costituiscono l'*outer training set* sul quale viene eseguita un'intera procedura di validazione incrociata (es. **GridSearchCV**) con k_{inner} fold interni per identificare la combinazione di iperparametri che massimizza la metrica di interesse (sottosezione 1.4.1). Il modello con gli iperparametri ottimali (*best model*) viene ri-addestrato sull'intero outer training set, e infine valutato sull'outer test set inizialmente accantonato e mai utilizzato né per la fase di addestramento né per l'individuazione del *best model*.

Figura 3: Nested cross-validation



Al termine delle k_{outer} iterazioni, si ottengono k_{outer} stime indipendenti delle prestazioni: la loro media e deviazione standard costituiscono una stima finale robusta e non distorta circa l'affidabilità e la capacità di generalizzazione del modello.

2.2.2 Step della pipeline

Si formalizza un aspetto metodologico cardine in relazione al rischio di data leakage: ciascuno degli step di pre-processing descritti di seguito viene inglobato in un unico blocco e ri-eseguito dinamicamente soltanto sul sottoinsieme di training nell'inner loop, e successivamente sull'intero outer training set in fase di refit finale.

I vari step della pipeline sono di seguito riportati in ordine di esecuzione.

1. **Scaling** (*RobustScaler*). A differenza della classica standardizzazione, che utilizza media e deviazione standard, il *robust scaling* scala i domini delle feature rispetto agli outlier.

$$X_{\text{scaled}} = \frac{X - \text{mediana}(X)}{\text{IQR}(X)} = \frac{X - Q_2}{Q_3 - Q_1}$$

dove Q_1 , Q_2 (mediana) e Q_3 sono rispettivamente il primo, secondo e terzo quartile della feature, calcolati sul training fold corrente. Tale tecnica consente di limitare l'influenza distorsiva degli outlier identificati in fase di esplorazione (sottosottosezione 2.1.2).

2. **Riduzione della multicollinearità** (*VIF*). Calcolo del VIF per ciascuna feature (sotto-sottosezione 2.1.1) e rimozione iterativa basata su soglia predefinita pari a 10.

3. **Feature selection** (*test di Welch*). Per ciascuna feature residua si esegue il test di Welch e si selezionano solamente le k feature con p-value più basso (sottosottosezione 2.2.3).
4. **Oversampling** (*SMOTE*). Per bilanciare artificialmente la proporzione delle classi vengono generate osservazioni sintetiche della classe minoritaria. Configurando a **auto** l'iperparametro **sampling_strategy**, si indica all'algoritmo di generare osservazioni sintetiche fino a quanto la classe minoritaria lo stesso volume di quella maggioritaria. È possibile quantificare esattamente l'impatto della trasformazione. Il dataset originale conta 569 osservazioni totali (357 benigne e 212 maligne). Poiché la trasformazione avviene sul *training set* dell'inner loop, la partizione di addestramento effettiva (che preserva il rapporto originale delle classi) è costituita da circa 364 istanze di cui 229 benigne e 135 maligne. La SMOTE inietta nel training set interno esattamente 94 nuove osservazioni maligne fino a raggiungere quota $229 = 135 + 94$, portando il volume finale dei dati di addestramento da 364 a 458 osservazioni.

2.2.3 Test di Welch

Il test di Welch è un test statistico univariato la cui applicazione consente di comprendere se le medie di due gruppi indipendenti sono tra loro diverse. Per ciascuna feature f , si isolano i due sottoinsiemi di osservazioni in base al **target**: l'insieme B – Benigno (**target** = 0) e l'insieme M – Maligno (**target** = 1). Si indica con $\mu_{f,B}$ e $\mu_{f,M}$ le medie della feature f nei due gruppi. Il test formalizza un confronto tramite una verifica delle ipotesi:


- **Ipotesi nulla** H_0 : $\mu_{f,B} = \mu_{f,M}$. La feature f non ha, in media, alcun potere discriminante tra le due classi.
- **Ipotesi alternativa** H_1 : $\mu_{f,B} \neq \mu_{f,M}$. Le medie della feature f differiscono realmente tra i due gruppi.

La decisione di rifiutare o meno H_0 si basa sul confronto tra il p-value e una soglia di significatività prefissata α (convenzionalmente pari a 0.05): se $p \leq \alpha$, si rigetta H_0 (esistono evidenze statistiche a favore di H_1) e si conclude che la feature ha un potere discriminante statisticamente significativo tra le due classi; viceversa, non rifiutare l'ipotesi nulla, non equivale a dimostrare in maniera rigorosa e formale che le medie siano uguali, bensì significa solo che i dati a disposizione non forniscono prove sufficienti per affermare il contrario.

Per utilizzare tale test come strumento di *feature selection*, le variabili vengono ordinate in modo crescente in base al loro p-value e, invece di fissare staticamente un numero di feature da conservare, la dimensione del sottoinsieme ottimale è stata inserita nello spazio degli iperparametri della pipeline. Nello specifico, si è definito un iperparametro $k \in \{0.1, 0.2, 0.3, \dots, 1.0\}$ (con passo pari a 0.1), dove ciascun valore indica la *percentuale* delle feature originali (classificate come top- k) da trattenere.

A supporto del test, viene riprodotta una visualizzazione introduttiva (Figura 4) che confronta le medie delle due classi lungo le 10 dimensioni morfologiche di base, ripetuta separatamente per ciascuno dei gruppi di aggregazione. Il grafico conferma che, in linea indicativa, per la quasi totalità delle dimensioni i valori associati ad istanze maligne sono in media superiori.

Figura 4: Confronto valori medi per gruppo



2.2.4 Selezione del modello migliore

Per illustrare concretamente il costo computazionale della ricerca esaustiva degli iperparametri si ricorre ad un esempio numerico. Si consideri un singolo modello di cui si vuole stabilire la combinazione di 7 iperparametri, ciascuno esplorato su una griglia di 4 valori (a cui si aggiunge l'iperparametro di pre-processing k precedentemente descritto, esplorato su 10 valori percentuali discreti).

Il numero di combinazioni valutate dalla *GridSearchCV* sarebbe $N_{\text{grid}} = 4^7 \times 10 = 163.840$. Siccome ciascuna procedura di tuning viene ripetuta indipendentemente per ciascuno dei fold sia dell'inner loop che dell'outer loop, assumendo che $k_{\text{outer}} = k_{\text{inner}} = 5$, il numero totale di addestramenti richiesti ($N = 163.840 \times 5 \times 5 = 4.096.000$) esplode combinatorialmente e diventa ai limiti del proponibile in un contesto con vincoli di risorse.

Un'alternativa può essere la **RandomSearch** [7], la quale consiste nel campionare casualmente un numero fissato N di combinazioni di iperparametri dallo spazio di ricerca. Il risultato teorico può esser derivato come segue.

Sia $\Omega^* \subset \Omega$ la regione dello spazio degli iperparametri che produce le configurazioni migliori, definite come il top $v\%$ delle configurazioni possibili (es. 95° percentile con $v = 0.05$). La probabilità di campionare casualmente una combinazione che non ricade in Ω^* è $1 - v$. Assumendo l'indipendenza degli N campionamenti, la probabilità che nessuna delle N combinazioni campionate ricada in Ω^* è pari a $(1 - v)^N$. Di conseguenza, la probabilità che in almeno uno degli N tentativi (campionamenti casuale di combinazioni) si ottenga un punto appartenente a Ω^* risulta essere

$$P = 1 - (1 - v)^N$$

Fissando l'obiettivo $P \geq 0.95$ e $v = 0.05$ (top 5% delle configurazioni), si può ricavare il numero minimo di tentativi N necessario come segue:

$$1 - (1 - 0.05)^N \geq 0.95 \implies 0.95^N \leq 0.05 \implies N \geq \frac{\ln(0.05)}{\ln(0.95)} \approx 58.4$$

Arrotondando, con $N = 60$ tentativi si supera la probabilità del 95% di raggiungere un punto dei top 5% (95° percentile). Il valore di N dipende esclusivamente dalla frazione di volume v che si intende raggiungere e non dalla dimensione dello spazio di ricerca Ω (spazio degli iperparametri). Questo è il motivo per cui risulta esser maggiormente conveniente degli approcci esaustivi al crescere esponenziale del numero di iperparametri. Applicando lo stesso schema, supposto $k_{\text{outer}} = k_{\text{inner}} = 5$, con $N_{\text{rand}} = 60$ iterazioni, il numero totale di addestramenti richiesti si riduce a $N = 60 \times 5 \times 5 = 1.500$.

2.2.5 Modelli di apprendimento

La pipeline precedentemente descritta viene eseguita indipendentemente per ciascuno dei seguenti quattro modelli:

- **Logistic Regression.** Modello probabilistico che stima direttamente la probabilità di appartenenza alla classe positiva applicando una funzione logistica a una combinazione lineare delle feature.
- **K-Nearest Neighbors (KNN).** Modello geometrico instance-based che classifica un'osservazione in base alla maggioranza delle etichette dei k vicini più prossimi nello spazio delle feature.
- **Random Forest.** Modello ensemble che aggrega le predizioni di numerosi alberi decisionali indipendenti, ciascuno addestrato su un campione del training set e su un sottoinsieme casuale di feature (bagging).
- **Support Vector Classifier.** Modello che individua l'iperpiano di separazione che massimizza il margine tra le classi.

Oltre al confronto individuale tra questi quattro modelli, vengono valutate due tecniche di ensemble che li combinano: **Soft Voting** e **Stacking**.

Il *Soft Voting* combina le predizioni dei quattro modelli base mediando le rispettive probabilità stimate per la classe positiva

$$\hat{p}(y = 1 \mid x) = \frac{1}{4} \sum_{i=1}^4 \hat{p}_i(y = 1 \mid x)$$

dove $\hat{p}_i$ è la probabilità stimata dall' i -esimo modello base. La classe finale predetta è quella con probabilità media più alta.

Per i modelli che non forniscono nativamente una stima di probabilità calibrata (es. *SVC*), per ragioni di compatibilità, sono stati applicati dei piccoli wrapper in modo da uniformare l'output (es. ²).

Il secondo approccio ensemble impiegato è lo *Stacking* a due livelli: un primo livello composto da più modelli di base indipendenti (*estimator*), e un secondo livello, il cosiddetto *blender*, addestrato non sui dati originali ma sulle predizioni prodotte dai modelli del primo livello.

²<https://scikit-learn.org/stable/modules/generated/sklearn.calibration.CalibratedClassifierCV.html>

Per evitare di ripetere da zero l'intera procedura di tuning degli iperparametri anche per l'ensemble, come estimator del primo livello vengono riutilizzati i modelli già ottimizzati nelle precedenti esecuzioni. Nello specifico, per ciascun fold dell'outer loop vengono presi i quattro *best model* (uno per ciascuno dei quattro estimator) risultanti dallo stesso outer fold.


A partire dagli estimator, viene costruito un nuovo dataset, detto *meta-train set*: per ciascuna osservazione del training set relativo ad un determinato outer fold, le quattro probabilità predette dagli estimator vengono affiancate alle label originali. È su questo nuovo dataset, a sole 4 dimensioni, che viene addestrato il blender. Come meta-learner è stato scelto intenzionalmente, vista la sua poca complessità, un **Logistic Regression**.

3 Risultati ottenuti

3.1 Confronto tra approcci di ricerca

Come anticipato in sottosottosezione 2.2.4, ciascun modello è stato ottimizzato sia tramite ricerca esaustiva sia tramite ricerca randomizzata, all'interno della medesima architettura di validazione incrociata innestata.

Figura 5: Confronto tra approcci di ricerca.



Il grafico in Figura 5 riassume, per ciascun modello, il valore di Recall medio e il tempo medio di fitting. I valori di tempo qui riportati assumono un ambiente di calcolo virtuale favorevole, in cui è possibile parallelizzare perfettamente il fitting dei diversi estimator, distribuendo il calcolo su risorse indipendenti. Sotto questa assunzione, il tempo di fitting (medio) del *Soft Voting* coincide con il tempo (medio) del più lento tra i quattro modelli di base che lo compongono (non a caso, il valore riportato per il *Soft Voting* risulta identico al valore riportato per il *Random Forest*). Per quanto riguarda lo *Stacking* invece, si aggiunge a questa stima il costo della selezione del best blender: mentre il Voting si limita a mediare le probabilità di modelli già addestrati, lo Stacking richiede la costruzione del meta-train set ed il fitting finale del meta-learner stesso.

Aggregando i risultati riportati in Figura 5 e in Tabella 4, si può notare che, più o meno per tutti i modelli, la differenza di recall tra i due approcci di ricerca è trascurabile rispetto alla variabilità naturale tra fold (le deviazioni standard per entrambi gli approcci risultano esser piuttosto esigue per tutti i modelli considerati). Sebbene ciò, si nota che nella metà dei casi l'approccio randomico eguaglia o supera la strategia esaustiva (pareggio nel caso di *LogisticRegression* e persino leggero miglioramento nel caso di *Soft Voting* e *Logistic Regression*). Questo piccolo risultato empirico conferma direttamente la teoria discussa in sottosottosezione 2.2.4: 60 campionamenti casuali sono sufficienti a individuare, con alta probabilità, una regione dello spazio degli iperparametri qualitativamente equivalente (o migliore) all'ottimo globale individuato dalla ricerca esaustiva.

A fronte di valori di Recall sostanzialmente quasi equivalenti, il vantaggio computazionale della *RandomSearch* è netto e cresce con la dimensionalità dello spazio di ricerca del modello. Il caso più evidente riguarda l'algoritmo *Random Forest* in cui si ha una riduzione di 31x. Anche per

Tabella 4: Confronto tra approcci di ricerca.

model	search_type	recall_std	time_std
KNeighborsClassifier	grid	0.066	0.590
	random	0.071	0.217
LogisticRegression	grid	0.042	0.707
	random	0.042	0.136
RandomForestClassifier	grid	0.058	5.157
	random	0.053	0.248
SVC	grid	0.045	2.980
	random	0.039	0.093
StackingClassifier	grid	0.053	6.602
	random	0.042	8.342
VotingClassifier	grid	0.049	5.157
	random	0.053	0.248

i modelli con spazio di ricerca più contenuto la riduzione resta comunque significativa, tra 3x e 5x.

3.2 Valutazione dei modelli

3.2.1 Matrici di confusione


Per un problema di classificazione binaria come quello in esame, la matrice di confusione organizza gli esiti delle predizioni in una tabella 2×2 , incrociando la classe reale (*True label*, sulle righe) con la classe predetta dal modello (*Predicted label*, sulle colonne). Da tale matrice si derivano le consuete metriche di valutazione.

	Predetto Benigno	Predetto Maligno
Reale Benigno	TN	FP
Reale Maligno	FN	TP

$$\begin{aligned}
 \text{Accuracy} &= \frac{TP+TN}{TP+TN+FP+FN} \\
 \text{Precision} &= \frac{TP}{TP+FP} \\
 \text{Recall} &= \frac{TP}{TP+FN} \\
 \text{F1} &= 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}
 \end{aligned}$$

La Figura 6 riporta, per ciascuna combinazione modello-strategia di ricerca, la matrice di confusione *aggregata*, ottenuta sommando le matrici di confusione calcolate su ciascuno dei $k_{\text{outer}} = 5$ fold esterni della nested cross-validation. Questa aggregazione è resa possibile da una proprietà strutturale della validazione incrociata: ciascuna delle 569 osservazioni del dataset compare come dato di test in uno e uno solo dei 5 fold esterni (mai in più di uno, né in nessuno), motivo per

Figura 6: Matrici di confusione per ciascuna combinazione modello-approccio di ricerca.



cui il totale di ciascuna matrice aggregata è esattamente pari al numero di istanze dell'intero dataset.

Dalla lettura delle 12 matrici (6 modelli $\times$ 2 approcci di ricerca) aggregate emergono alcune osservazioni rilevanti. Sommando FP e FN, la configurazione *Stacking (random)* ottiene un numero totale di errori pari a 11 ($FP = 2$, $FN = 9$) inferiore a tutte le altre 11 combinazioni. Inoltre, delle 12 configurazioni, solamente 3 mostrano un numero di FN inferiore al numero di FP: *Logistic Regression (grid)* ($FN = 9 < FP = 11$), *Random Forest (grid)* ($FN = 11 < FP = 15$) e *Random Forest (random)* ($FN = 12 < FP = 13$). Tra queste tre, *Logistic Regression (grid)* presenta il totale di errori più contenuto ($FP + FN = 20$). Complessivamente, il *Logistic Regression* risulta essere il modello con valore medio di recall più elevato.

Osservando i risultati per singolo fold esterno (anziché aggregati), emergono alcune configurazioni particolarmente favorevoli o sfavorevoli. Su 60 combinazioni, in ben 18 casi si osserva una recall massima (nessun falso negativo), un risultato che ricorre con assoluta frequenza sui fold esterni n.1 e n.4, suggerendo che questi contengano, per pura casualità della suddivisione stratificata, una composizione di osservazioni maligne particolarmente "facili" da classificare correttamente.

I risultati mostrati dimostrano come la sola applicazione di SMOTE non basti ad eliminare completamente un residuo vantaggio nella predizione della classe maggioritaria. Per mitigare tale problema, si è deciso di valutare una calibrazione della **soglia di decisione**, dato che, di default, la soglia sulla probabilità stimata $\hat{p}(y = 1 | x)$ oltre la quale un'osservazione viene classificata come maligna è fissata a 0.5.

Per ciascun outer fold, i best model vengono ri-addestrati esclusivamente sull'outer training set di riferimento, con l'obiettivo di massimizzare la metrica di F-beta ($\beta = 2$), che pesa la Recall quattro volte più della Precision:

$$F_2 = 5 \cdot \frac{\text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}$$

La soglia così individuata viene poi applicata sull'outer test set, dove si misurano le Recall e Precision "tuned". Sulle 60 configurazioni complessive, la soglia media individuata è pari a 0.371 (deviazione standard 0.101). La quasi totalità delle soglie ottimali si colloca ben al di sotto del valore di default 0.5 (coerentemente con l'obiettivo di aumentare la sensibilità alla classe maligna) sebbene in 4 casi (3 dei quali con il *Logistic Regression*) la soglia supera lo 0.5.

Tabella 5: Risultati ottenuti con soglia di probabilità ottimizzata.

Modello	Soglia	Recall	Recall (tuned)	Precision	Precision (tuned)
KNeighborsClassifier	0.397	0.9175	0.924	0.948	0.930
LogisticRegression	0.445	0.957	0.967	0.962	0.960
RandomForestClassifier	0.379	0.945	0.962	0.939	0.897
SVC	0.334	0.945	0.962	0.956	0.942
StackingClassifier	0.312	0.952	0.966	0.982	0.954
VotingClassifier	0.360	0.945	0.976	0.979	0.945

In Tabella 5 sono riportati i valori medi di recall e precision per ciascun modello. Come previsto, per tutti i modelli, la calibrazione della soglia produce un aumento di recall a fronte di una diminuzione di precision. Tutti i modelli mostrano ovviamente un guadagno positivo per la f-beta score.

3.2.2 Tempi di inferenza

La Tabella 6 riporta per ciascun modello il tempo medio di inferenza sull'intero test set.

Tabella 6: Tempo medio di inferenza sull'intero test set.

Modello	Tempo inferenza medio (s)
LogisticRegression	0.00205
SVC	0.00230
KNeighborsClassifier	0.00291
RandomForestClassifier	0.00589
StackingClassifier	0.01019
VotingClassifier	0.01143

Come atteso, gli approcci di ensemble (*Random Forest*, *Voting* e *Stacking*) risultano complessivamente i più lenti in fase di inferenza: essi necessitano di interrogare tutti gli estimator (più, nel caso dello *Stacking*, il blender) per produrre una singola predizione. Tra i modelli "semplici", invece, le tempistiche riflettono fedelmente la loro complessità.. Infatti, essendo il KNN l'unico modello *instance-based* (calcolo a runtime delle distanze euclidee per considerare il vicinato), richiede tempi sensibilmente superiori rispetto ai modelli lineari o compatti come la *Logistic Regression* e l'*SVC*.

Sebbene si tratti comunque di differenze di ordine di grandezza contenuto, in un'ottica di *scalabilità* la latenza può assumere una posizione decisiva. Comprendere le tempistiche entro cui un modello produce un output risulta infatti cruciale soprattutto in un contesto sanitario.

3.3 Explainability

Il concetto di explainability fa riferimento alla capacità di rendere interpretabili e comprensibili le decisioni prese da un modello. In ambito medico diventa quasi un prerequisito imprescindibile per questione etiche e legali sollevate dalla considerazione di modelli complessi come *black box*.

L'utilizzo di tali strumenti e l'accettazione di eventuali diagnosi necessitano di spiegazioni quanto più trasparenti possibile.

Un primo elemento di analisi, propedeutico all'explainability vera e propria, riguarda la stabilità della fase di feature selection nelle diverse esecuzioni della pipeline. Per ciascuna feature sopravvissuta almeno una volta alla selezione, è stato conteggiato il numero di volte in cui compare tra le feature effettivamente utilizzate dal modello finale, su un totale di 40 fit indipendenti (4 modelli $\times$ 5 fold $\times$ 2 search type, esclusi le due strategie di ensemble). La Tabella 7 riporta le feature con frequenza di selezione più alta.

Tabella 7: Frequenza caratteristiche sopravvissute alla pipeline.

Feature	Frequenza (su 40)	Percentuale
concave_points_error	39	97,5%
mean_texture	38	95,0%
worst_smoothness	36	90,0%
mean_concave_points	32	80,0%
perimeter_error	32	80,0%
worst_area	32	80,0%
worst_symmetry	29	72,5%
mean_smoothness	28	70,0%
mean_symmetry	20	50,0%
compactness_error	9	22,5%
concavity_error	8	20,0%
mean_radius	8	20,0%
area_error	8	20,0%
worst_concavity	8	20,0%
worst_fractal_dimension	6	15,0%
smoothness_error	2	5,0%

Un risultato particolarmente significativo riguarda le tre dimensioni (**worst_area**, **worst_smoothness** e **mean_texture**) individuate staticamente nel lavoro originale per separare efficacemente le unità benigne da quelle maligne [5]. Nel presente lavoro, pur attuando un criterio di selezione rigoroso, queste tre feature mantengono una frequenza molto elevata (rispettivamente 80%, 90% e 95%). Ciò evidenzia che il metodo proposto non produca risultati arbitrari e/o totalmente sconnessi dalla letteratura di riferimento.

3.3.1 Spazio delle feature

Come discusso in sottosottosezione 2.2.2, la pipeline riduce lo spazio delle 30 feature originarie in due passaggi successivi: prima tramite eliminazione iterativa basata su VIF, poi tramite selezione top- k basata sul t-test di Welch, dove k è espresso come percentuale (**welch__percentage**) ed è trattato come iperparametro nella grid/random search (sottosottosezione 2.2.3).

Il primo passaggio (VIF) rimane deterministico nei vari fold tra tutti i modelli in quanto dipende esclusivamente dallo split dei dati. Il secondo passaggio (Welch, con k tunato) produce invece una dimensionalità finale più variabile, sia tra modelli sia tra fold, riassunta nella Tabella 8.

Tabella 8: Dimensionalità media dello spazio delle feature per modello.

Modello	N. feature medio (post-Welch)
SVC	9.1
RandomForestClassifier	8.9
LogisticRegression	8.3
KNeighborsClassifier	7.2

È interessante notare, che sulle configurazioni complessive dell’esperimento, i due valori più estremi di k (0.1 e 0.2), corrispondenti a un sottoinsieme di appena 2 feature sulle 16 sopravvissute in media al VIF, non sono mai stati selezionati come ottimali in nessuna delle esecuzioni. Il caso di riduzione dimensionale più aggressivo riscontrato nell’intero esperimento è per il fold n.2 per il *KNeighborsClassifier (grid)*, ossia $k = 0.3$. In tale step sono state selezionate solamente 3 feature delle 17 sopravvissute al filtro VIF: `mean_concave_points`, `worst_area` e `perimeter_error`. Con questo sottoinsieme estremamente ridotto, il modello ottiene comunque una Recall di 0.86 e un’Accuracy di 0.921.

3.3.2 Importanza delle feature


Per l’analisi di explainability, viene impiegato **SHAP** (*SHapley Additive exPlanations*) [8], un framework che quantifica il contributo di ciascuna feature a una singola predizione tramite valori SHAP: valori positivi spingono la predizione verso la classe maligna, valori negativi verso la classe benigna.

Applicando SHAP a ciascuna delle 12 configurazioni modello-strategia di ricerca, emergono due risultati degni di nota. In primo luogo, in ben 8 casi su 12, le 3 feature individuate manualmente nel paper originale (`worst_area`, `worst_smoothness`, `mean_texture`) compaiono tra le prime 4 feature per valore SHAP medio; ciò è un’ulteriore conferma della rilevanza diagnostica di queste tre dimensioni morfologiche. In secondo luogo, la feature `mean_concave_points` risulta, in tutte e 12 le configurazioni, tra le prime due feature per importanza SHAP, a suggerire che essa sia la feature con il potere discriminante più stabile.

La Figura 7 mostra un *beeswarm plot* applicato sulla configurazione *SVC (grid)*, una delle visualizzazioni standard per riassumere i valori SHAP sull’intero test set. Ogni riga corrisponde a una feature (ordinate dall’alto verso il basso per importanza media decrescente, misurata come valore SHAP assoluto medio su tutte le osservazioni); sull’asse delle ascisse è riportata la scala dei valori SHAP ed ogni punto rappresenta una singola osservazione del test set, posizionato orizzontalmente proprio in base al valore SHAP per quella feature; il colore del punto codifica invece il valore effettivo che quella feature assume per quell’osservazione.

Per `worst_area`, la feature più importante nella configurazione mostrata, si osserva una separazione quasi netta: i punti blu (valori bassi) si concentrano quasi esclusivamente su valori SHAP negativi, mentre i punti rossi (valori alti) si distribuiscono prevalentemente su valori SHAP positivi. Un pattern analogo, sebbene con dispersione minore, si osserva per `mean_concave_points` e `worst_smoothness`. Si nota inoltre come ci siano alcuni casi isolati per `compactness_error`, `smoothness_error` e `concavity_error`: queste osservazioni con valore SHAP fortemente negativo (o positivo) meriterebbero un’ispezione puntuale (capire quali pazienti sono) se si volesse approfondire ulteriormente la loro anomalia.

Figura 7: Importanza delle feature tramite SHAP - SVC (grid)



4 Conclusioni

Il presente lavoro nasce dalla lacuna individuata nel lavoro originale relativo al dataset "*Breast Cancer Wisconsin*", L'intero impianto sperimentale è stato costruito per rispondere a questa lacuna in modo rigoroso, e i risultati ottenuti permettono di trarre alcune conclusioni di fondo.

Il risultato forse più significativo dell'intero lavoro è che il modello complessivamente migliore (considerando congiuntamente prestazioni diagnostiche e costo computazionale, sia in fase di training sia di inferenza) non è un modello complesso o un ensemble, ma la *Logistic Regression*, l'algoritmo più semplice tra quelli confrontati. Questo risultato risulta coerente con la natura didattica del dataset impiegato, in quanto estremamente pulito, privo di rumore significativo, con classi ben separabili nello spazio delle feature originarie. Su un problema di classificazione con una struttura sottostante già fortemente lineare e ben separabile, la maggiore capacità rappresentativa di modelli più complessi non si traduce in un vantaggio diagnostico proporzionale al costo computazionale aggiuntivo che essi richiedono.

Al di là delle prestazioni diagnostiche in sé, uno dei contributi più solidi di questo lavoro riguarda la *stabilità* del criterio di feature selection: il sottoinsieme di feature individuato si è dimostrato coerente attraverso modelli diversi, strategie di ricerca diverse e suddivisioni diverse del dataset, convergendo peraltro, in larga parte, sulle stesse dimensioni morfologiche individuate manualmente dal lavoro originale.

In aggiunta, il confronto sistematico tra le due strategie di ricerca (**GridSearch** e **RandomSearch**) conferma empiricamente quanto previsto dal fondamento teorico. A parità di modello, la ricerca randomica raggiunge, prestazioni sostanzialmente equivalenti (e in diversi casi superiori) alla ricerca esaustiva, a fronte di un costo computazionale drasticamente inferiore.

In sintesi, il presente lavoro dimostra che la lacuna metodologica del paper originale può essere colmata con un criterio automatico, stabile e rigoroso, ma suggerisce anche che la scelta metodologica corretta pesa spesso più della scelta del modello più sofisticato/complesso in senso assoluto.

Riferimenti bibliografici

- [1] International Agency for Research on Cancer. “GLOBOCAN 2024: Breast Cancer Fact Sheet.” Global Cancer Observatory, International Agency for Research on Cancer, World Health Organization, visitato il giorno 14 ago. 2026. indirizzo: <https://gco.iarc.who.int/media/globocan/factsheets/cancers/20-breast-fact-sheet.pdf>.
- [2] World Health Organization. “Breast Cancer.” Fact sheet, World Health Organization. indirizzo: <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>.
- [3] O. Freihat, D. Sipos e A. Kovacs, “Global burden and projections of breast cancer incidence and mortality to 2050: a comprehensive analysis of GLOBOCAN data,” *Frontiers in Public Health*, vol. Volume 13 - 2025, 2025, issn: 2296-2565. DOI: [10.3389/fpubh.2025.1622954](https://doi.org/10.3389/fpubh.2025.1622954). indirizzo: <https://www.frontiersin.org/journals/public-health/articles/10.3389/fpubh.2025.1622954>.
- [4] A. N. Giaquinto et al., “Breast cancer statistics 2024,” *CA: A Cancer Journal for Clinicians*, vol. 74, n. 6, pp. 477–495, 2024. DOI: <https://doi.org/10.3322/caac.21863>. eprint: <https://acsjournals.onlinelibrary.wiley.com/doi/pdf/10.3322/caac.21863>. indirizzo: <https://acsjournals.onlinelibrary.wiley.com/doi/abs/10.3322/caac.21863>.
- [5] W. N. Street, W. H. Wolberg e O. L. Mangasarian, “Nuclear feature extraction for breast tumor diagnosis,” in *Electronic imaging*, 1993. indirizzo: <https://api.semanticscholar.org/CorpusID:14922543>.
- [6] F. T. Liu, K. M. Ting e Z.-H. Zhou, “Isolation Forest,” in *2008 Eighth IEEE International Conference on Data Mining*, 2008, pp. 413–422. DOI: [10.1109/ICDM.2008.17](https://doi.org/10.1109/ICDM.2008.17).
- [7] J. Bergstra, “Random Search for Hyper-Parameter Optimization,” *The Journal of Machine Learning Research*, vol. 13, pp. 281–305, mar. 2012.
- [8] S. M. Lundberg e S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” in *Advances in Neural Information Processing Systems*, I. Guyon et al., cur., vol. 30, Curran Associates, Inc., 2017. indirizzo: https://proceedings.neurips.cc/paper_files/paper/2017/file/8a20a8621978632d76c43dfd28b67767-Paper.pdf.